

Predição de Risco na Gestaç o utilizando Redes Neurais Densas

Arthur Vasconcelos de O. R. Porci ncula

Universidade Federal de Pernambuco
Departamento de Estat stica - CCEN/UFPE

Disciplina: Redes Neurais
Prof. Dr. Jodavid Ferreira

3 de Dezembro de 2025

Sumário

- 1 Introdução
- 2 Metodologia
- 3 Análise descritiva
- 4 Modelo de Redes Neurais
- 5 Conclusão
- 6 Referências

Desafios da gestação

- A gestação é um período caracterizado por intensas mudanças fisiológicas e emocionais, exigindo acompanhamento contínuo para prevenir complicações que podem afetar tanto a mãe quanto o feto.
- Alterações discretas em sinais vitais podem indicar o início de quadros clínicos graves, como diabetes gestacional, infecções maternas e sofrimento fetal, todos associados a desfechos potencialmente fatais quando não detectados de forma precoce.



Desafios da gestação

- Em regiões remotas ou com infraestrutura limitada, a identificação precoce de riscos maternos é um desafio significativo, contribuindo para índices elevados de doenças e mortalidade materna e neonatal.
- Monitorar **variáveis clínicas simples** como pressão arterial, frequência cardíaca, temperatura corporal e glicemia torna-se fundamental, pois alterações nessas medições frequentemente antecedem eventos adversos mais graves.
- Modelos de aprendizado de máquina, como redes neurais, são capazes de capturar relações não lineares entre variáveis fisiológicas e desfechos clínicos. Ao integrar múltiplos parâmetros biomédicos, essas redes podem identificar padrões complexos e oferecer **estimativas de risco** consistentes.

Dados e variáveis

Os dados foram coletados de diferentes hospitais, clínicas comunitárias e centros de saúde materna de áreas rurais de Bangladesh, possuindo 1014 observações de 6 variáveis explicativas, além do **nível de risco** (baixo, médio ou alto):

- Idade, em anos;
- Pressão arterial sistólica (PAS), em mmHg;
- Pressão arterial diastólica (PAD), em mmHg;
- Nível de glicose no sangue, em mmol/L;
- Temperatura corporal, em °F;
- Frequência cardíaca, em bpm.

Rede Neural Totalmente Conectada

- Tipo de rede neural em que cada nó (ou neurônio) de uma camada é conectada a todos os nós da camada seguinte.
- Seja $\mathbf{X} \in \mathbb{R}^{n \times p}$ a matriz de valores de entrada com n observações e p *features*, \mathbf{O} a saída do modelo e \mathbf{H} uma variável de camada oculta. Um **MLP** (rede neural densa) com d camadas ocultas pode ser construída como:

Rede Neural Totalmente Conectada

$$\begin{aligned}\mathbf{H}^{(1)} &= \varphi_1\left(\mathbf{X}\mathbf{W}^{(1)} + \mathbf{b}^{(1)}\right), \\ \mathbf{H}^{(2)} &= \varphi_2\left(\mathbf{H}^{(1)}\mathbf{W}^{(2)} + \mathbf{b}^{(2)}\right), \\ &\vdots \\ \mathbf{O} &= \varphi_g\left(\mathbf{H}^{(d)}\mathbf{W}^{(d)} + \mathbf{b}^{(d)}\right)\end{aligned}$$

em que $\mathbf{W}^{(i)}$ e $\mathbf{b}^{(i)}$ são, respectivamente, a matriz de pesos e o viés da i -ésima camada oculta; e $\varphi_i(\cdot)$ é a função de ativação da i -ésima camada oculta.

Rede Neural Totalmente Conectada

- A cada época (iteração), os valores dos pesos e vieses são reajustados, utilizando o algoritmo de *backpropagation*. Os ajustes são realizados por meio de um **otimizador**, de forma que a **função de perda** escolhida seja minimizada e os resultados sejam mais precisos.
- **Dropout**: Desliga aleatoriamente uma fração dos neurônios durante o treinamento (probabilidade p de desligamento para cada neurônio). Isso força a rede a não depender de neurônios específicos, mas sim a aprender representações mais robustas dos dados, reduzindo o risco de *overfitting*.

Funções de ativação

A seguir, são descritas as funções de ativação e a função de perda presentes no modelo final.

- A função de ativação **ReLU** é definida por

$$\text{ReLU}(x) = \max(0, x),$$

em que x representa o valor de entrada do nó.

- A função **softmax** é dada por

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}},$$

em que z_i é o i -ésimo componente do vetor de entradas \mathbf{z} e K é o número total de classes.

Função de perda

- A função de perda de **entropia cruzada** é definida por

$$\mathcal{L} = - \sum_{i=1}^K y_i \log(\hat{y}_i),$$

em que K representa o número de classes, y_i é o valor alvo indicando a classe (1, se é a correta; 0, se não é) e \hat{y}_i é a probabilidade prevista pelo modelo para a classe i .

Análise descritiva

- Inicialmente, são retiradas duas observações inconsistentes (apresentam frequência cardíaca igual a 7), resultando em 1012 observações no conjunto.
- A amostra resultante apresenta 39.92% das observações como baixo risco, 33.20% como médio risco e 26.88% como alto risco.
- Todas as variáveis explicativas são discretas (com exceção do nível de glicose, que tem precisão de uma casa decimal), o que acarreta numa menor variedade de valores na amostra, e numa precisão mais baixa desses descritores biológicos.
- Pelo coeficiente τ de Kendall, há uma correlação considerável entre PAS e PAD ($\tau = 0.64$). As demais correlações entre covariáveis são todas fracas, com valores inferiores a 0.4.

Análise descritiva

Figura 1: Densidade da amostra segundo o nível de risco e a idade.


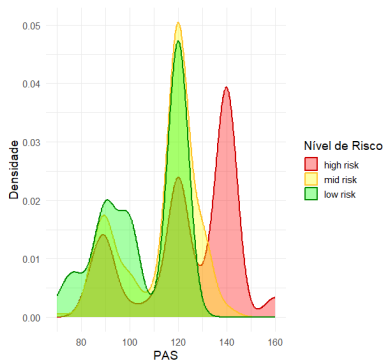


Figura 2: Densidade da amostra segundo o nível de risco e a PAS.



Análise descritiva

Figura 3: Densidade da amostra segundo o nível de risco e a PAD.

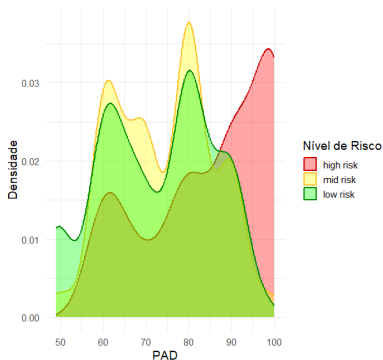



Figura 4: Densidade da amostra segundo o nível de risco e o nível de glicose no sangue.



Análise descritiva

Figura 5: Densidade da amostra segundo o nível de risco e a temperatura corporal.





Figura 6: Densidade da amostra segundo o nível de risco e a frequência cardíaca.



Modelo de Redes Neurais


Foram ajustados 10 diferentes modelos de redes neurais densas, variando o número de camadas, o número de neurônios por camada, o parâmetro do *dropout*, funções de ativação e otimizadores.

O melhor, gerado em 100 épocas, utiliza o otimizador *Adam*, função de perda de entropia cruzada e tem a seguinte estrutura:

- Primeira camada com 32 neurônios, utilizando a função *ReLU* e *Dropout* com parâmetro 0.2;
- Segunda camada com 16 neurônios, utilizando a função *ReLU* e *Dropout* com parâmetro 0.1;
- Terceira camada com 8 neurônios, utilizando a função *ReLU*;
- Camada de saída com 3 neurônios, utilizando a função *softmax*.

Desempenho do modelo

Figura 7: Gráficos de acurácia e *loss* do modelo para treinamento e validação, ao longo das épocas.



Desempenho do modelo

Tabela 1: Matriz de confusão do modelo

Real / Predito	Risco baixo	Risco médio	Risco alto
Risco baixo	67	11	5
Risco médio	24	38	10
Risco alto	1	4	43

- O modelo apresenta acurácia de 72.91% e Kappa de Cohen aproximadamente igual a 0.59, métricas que confirmam que o modelo é razoável.
- O modelo prediz muito bem observações de risco alto como realmente tendo risco alto (89.58% de acertos para essa classe), sendo essa a principal preocupação do estudo.





Desempenho do modelo

- O modelo também prediz bem os riscos baixos, acertando 80.72% dessa classe.
- O ponto fraco é a predição para observações de risco médio, que são frequentemente classificadas como uma das outras classes (o acerto para esse grupo é de 52.78%).

Principais conclusões

- Esse modelo, a partir de variáveis facilmente coletadas em atendimentos básicos, pode apoiar profissionais de saúde na priorização de atendimentos, permitindo identificar casos que demandam acompanhamento mais próximo, enquanto outros podem ser monitorados à distância sem prejuízo clínico.
- Apesar do desafio imposto pelos dados por serem em sua maioria discretos, o modelo final apresenta um bom desempenho, principalmente classificando as pacientes cujo risco real é alto, e também classificando bem aquelas com risco real baixo.
- A principal limitação foi a distinção entre o grupo de risco médio e os demais, possivelmente devido à própria natureza do problema: em diversas variáveis, a distribuição desse grupo quase se sobrepõe à do grupo de baixo risco, dificultando a separação clara entre as classes.

Referências I

-  T. B. Ludemir, A. P. Braga, and A. Carvalho, “Redes neurais artificiais: teoria e aplicações,” *Livros Técnicos e Científicos Editora*, p. 17, 2000.
-  M. Ahmed, “Maternal Health Risk,” UCI Machine Learning Repository, 2020, DOI: <https://doi.org/10.24432/C5DP5D>.
-  P. K. Whelton, R. M. Carey, W. S. Aronow *et al.*, “2017 guideline for high blood pressure in adults,” *Hypertension*, vol. 71, no. 6, pp. e13–e115, 2017.
-  A. D. Association, “Standards of medical care in diabetes—2022,” *Diabetes Care*, vol. 45, no. Suppl 1, pp. S1–S264, 2022.