

# Predição de Risco na Gestação utilizando Redes Neurais Densas

Arthur Vasconcelos de O. R. Porciúncula  
Departamento de Estatística - CCEN/UFPE  
Prof. Dr. Jodavid Ferreira  
Disciplina: Redes Neurais

30 de Novembro de 2025

## 1 Introdução

A gestação é um período caracterizado por intensas mudanças fisiológicas e emocionais, exigindo acompanhamento contínuo para prevenir complicações que podem afetar tanto a mãe quanto o feto. Alterações aparentemente discretas em sinais vitais podem indicar o início de quadros clínicos graves, como pré-eclâmpsia, diabetes gestacional, infecções maternas e sofrimento fetal, todos associados a desfechos potencialmente fatais quando não detectados de forma precoce.

Em especial em regiões remotas ou com infraestrutura limitada, a identificação precoce de riscos maternos continua sendo um desafio significativo, contribuindo para índices elevados de doenças e mortalidade materna e neonatal. Nesse cenário, a capacidade de monitorar variáveis clínicas simples como pressão arterial, frequência cardíaca, temperatura corporal, saturação de oxigênio e glicemia torna-se fundamental, pois alterações nessas medições frequentemente antecedem eventos adversos mais graves.

Nesse contexto, modelos de aprendizado de máquina, especialmente as redes neurais totalmente conectadas, podem se mostrar capazes de capturar relações não lineares entre variáveis fisiológicas e desfechos clínicos. Ao integrar múltiplos parâmetros biomédicos, essas redes podem identificar padrões complexos que escapam à análise humana tradicional, oferecendo estimativas de risco mais rápidas, consistentes e adaptáveis.

Esse estudo, portanto, pretende desenvolver um modelo de redes neurais densas para predição do risco associado à gravidez, utilizando dados coletados de diferentes hospitais, clínicas comunitárias e centros de saúde materna de áreas rurais de Bangladesh [1].

## 2 Fundamentos Teóricos e Metodológicos

O conjunto de dados possui 1014 observações de 6 variáveis explicativas, além do nível de risco (baixo, médio ou alto):

- Idade, em anos;
- Pressão arterial sistólica (PAS), em mmHg;
- Pressão arterial diastólica (PAD), em mmHg;
- Nível de glicose no sangue, em mmol/L;
- Temperatura corporal, em °F;
- Frequência cardíaca, em bpm.

Uma rede neural densa é um tipo de rede neural em que as camadas são totalmente conectadas, isto é, cada nó ou neurônio de uma camada é conectada a todos os nós (neurônios) da camada seguinte [2]. Seja  $\mathbf{X} \in \mathbb{R}^{n \times p}$  a matriz de valores de entrada com  $n$  observações e  $p$  *features*,  $\mathbf{O}$  a saída do modelo e  $\mathbf{H}$  uma variável de camada oculta. Um MLP (rede neural densa) com  $d$  camadas ocultas pode ser construída como:

$$\begin{aligned}\mathbf{H}^{(1)} &= \varphi_1(\mathbf{X}\mathbf{W}^{(1)} + \mathbf{b}^{(1)}), \\ \mathbf{H}^{(2)} &= \varphi_2(\mathbf{H}^{(1)}\mathbf{W}^{(2)} + \mathbf{b}^{(2)}), \\ &\vdots \\ \mathbf{O} &= \varphi_g(\mathbf{H}^{(d)}\mathbf{W}^{(d)} + \mathbf{b}^{(d)}),\end{aligned}$$

em que  $\mathbf{W}^{(i)}$  e  $\mathbf{b}^{(i)}$  são, respectivamente, a matriz de pesos e o viés da  $i$ -ésima camada oculta; e  $\varphi_i(\cdot)$  é a função de ativação da  $i$ -ésima camada oculta.

## 3 Aplicação

### 3.1 Análise Descritiva


Inicialmente, são retiradas duas observações inconsistentes (com frequência cardíaca igual a 7), e a amostra resultante apresenta 39.92% das observações como baixo risco, 33.20% como médio risco e 26.88% como alto risco. É importante ressaltar, também, que todas as variáveis explicativas são discretas (com exceção do nível de glicose, que tem precisão de uma casa decimal), o que acarreta numa menor variedade de valores na amostra, e numa precisão mais baixa desses descritores biológicos.

Verifica-se, através do coeficiente  $\tau$  de Kendall, uma correlação considerável entre PAS e PAD ( $\tau = 0.64$ ). As demais correlações entre covariáveis são todas fracas, com valores inferiores a 0.4.

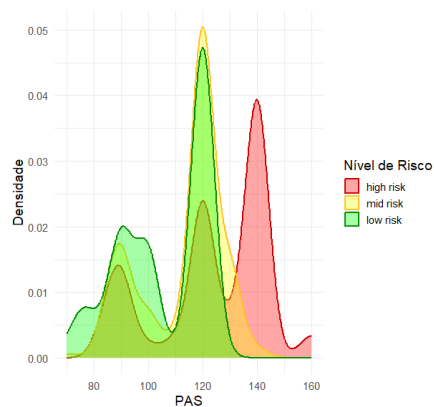
Observamos que o grupo de risco alto geralmente apresenta idades maiores que os demais, principalmente a partir da faixa superior dos 30 anos. Note que há uma quantidade considerável de casos de mães adolescentes na amostra, com a idade mínima de 10 anos. Para uma PAS com valores ao redor de 140, a chance de a observação ser considerada de risco alto é muito grande; já para a PAD, a partir de 90 mmHg já é um indício forte de alto risco. De fato, a PAS considerada saudável está entre 90 e 119 mmHg; já a PAD, entre 60 e 79 mmHg [3].

O nível de glicose considerado razoável no sangue são valores inferiores a 7.8 mmol/L [4]. Constatamos que a maioria das pacientes com baixo e médio risco apresentam valores ao redor dessa faixa; as de alto risco comumente apresentam valores superiores a esse limite. Por outro lado, grupos de médio e alto risco apresentam, em geral, maior predomínio de observações com temperatura corporal entre 100 °F a 103 °F em relação ao de baixo risco (a faixa de 97 °F a 99 °F é considerada saudável). Os grupos de baixo e médio risco apresentam densidades com picos de frequência cardíaca em torno de 70 e de 78 bpm superiores ao de alto risco, e pico de frequência cardíaca de 87 bpm inferior ao de alto risco. Isso sugere que frequências cardíacas maiores tendem a se correlacionar com um risco maior. Estas análises são feitas a partir da Figura 1.


Figura 1: Curvas de densidade da amostra segundo o nível de risco e as variáveis explicativas.



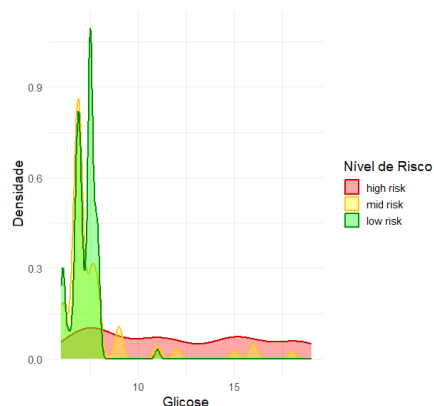
((a)) Idade.




((b)) PAS.



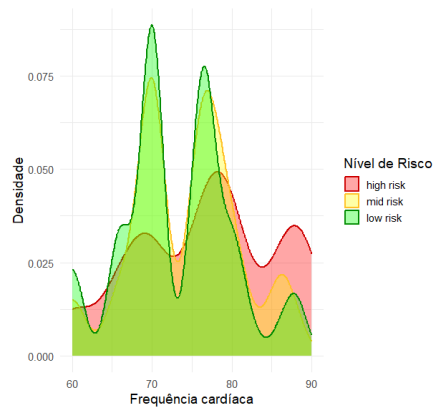
((c)) PAD.



((d)) Nível de glicose no sangue.



((e)) Temperatura corporal.



((f)) Frequência cardíaca.

### 3.2 Modelos de Redes Neurais

Ajustamos 10 diferentes modelos de redes neurais densas, variando o número de camadas, o número de neurônios por camada, o parâmetro do *dropout*, funções de otimização e otimizadores. O melhor, gerado em 100 épocas, utiliza o otimizador *Adam*, função de perda de entropia cruzada (essa foi utilizada em todos), busca maximizar a acurácia e tem a seguinte estrutura:

- Primeira camada com 32 neurônios, utilizando a função *ReLU* e *Dropout* com parâmetro 0.2;
- Segunda camada com 16 neurônios, utilizando a função *ReLU* e *Dropout* com parâmetro 0.1;
- Terceira camada com 8 neurônios, utilizando a função *ReLU*;
- Camada de saída com 3 neurônios, utilizando a função *softmax*.

Através da Figura 2, observa-se que ao longo das épocas, a acurácia (tanto de treino, quanto de validação) aumenta, enquanto a perda da validação se estabiliza em torno da época 40 e a perda de treino segue decrescendo. Como a acurácia de validação segue estável e convergindo para a de treino, não há indícios de *overfitting* no modelo.

Figura 2: Gráficos de acurácia e *loss* do modelo para treinamento e validação, ao longo das épocas.




Tabela 1: Matriz de confusão do modelo

| Real / Predito | Risco baixo | Risco médio | Risco alto |
|----------------|-------------|-------------|------------|
| Risco baixo    | 67          | 11          | 5          |
| Risco médio    | 24          | 38          | 10         |
| Risco alto     | 1           | 4           | 43         |

O modelo apresenta acurácia de 72.91% e Kappa de Cohen aproximadamente igual a 0.59, métricas que confirmam que o modelo é razoável. O maior trunfo, entretanto, é que o modelo prediz muito bem observações de risco alto como realmente tendo risco alto (89.58% de acertos para essa classe), sendo essa a principal preocupação do estudo. O modelo também prediz bem os riscos baixos, acertando 80.72% dessa classe; o ponto fraco é a predição para observações de risco médio, que são frequentemente classificadas como uma das outras classes (o acerto para esse grupo é de 52.78%), conforme a Tabela 1.

## 4 Conclusão

Neste estudo, buscou-se desenvolver um modelo capaz de prever o risco de doenças ou outras complicações na gravidez a partir de variáveis facilmente coletadas em atendimentos básicos. Tal abordagem é especialmente útil em regiões com recursos limitados, onde exames especializados nem sempre estão disponíveis. Um modelo preditivo desse tipo pode apoiar profissionais de saúde na priorização de atendimentos, permitindo identificar casos que demandam acompanhamento mais próximo, enquanto outros podem ser monitorados à distância sem prejuízo clínico.

Apesar do desafio imposto pelos dados por serem em sua maioria discretos, o modelo final apresenta um ótimo desempenho, principalmente classificando as pacientes cujo risco real é alto, e também classificando bem aquelas com risco real baixo. A principal limitação foi a distinção entre o grupo de risco médio e os demais, possivelmente devido à própria natureza do problema: em diversas variáveis, a distribuição desse grupo quase se sobrepõe à do grupo de baixo risco, dificultando a separação clara entre as classes.

No geral, os resultados reforçam que redes neurais densas são capazes de capturar padrões relevantes em variáveis fisiológicas simples, constituindo uma ferramenta promissora para apoio à triagem e monitoramento materno, especialmente em contextos de restrição tecnológica.

## Referências

- [1] M. Ahmed, “Maternal Health Risk,” UCI Machine Learning Repository, 2020, DOI: <https://doi.org/10.24432/C5DP5D>.
- [2] T. B. Ludemir, A. P. Braga, and A. Carvalho, “Redes neurais artificiais: teoria e aplicações,” *Livros Técnicos e Científicos Editora*, p. 17, 2000.
- [3] P. K. Whelton, R. M. Carey, W. S. Aronow *et al.*, “2017 guideline for high blood pressure in adults,” *Hypertension*, vol. 71, no. 6, pp. e13–e115, 2017.
- [4] A. D. Association, “Standards of medical care in diabetes—2022,” *Diabetes Care*, vol. 45, no. Suppl 1, pp. S1–S264, 2022.